

Fonctionnement d'un GraphSage

Sherelle Kana

April 1, 2024

Sommaire

- 1 **Introduction**
- 2 **Entrées / Sorties**
- 3 **Fonctionnement**
- 4 **Avantages**
- 5 **Limites**

Introduction

Les GNNs classiques sont transductifs.

Le fonctionnement des modèles classiques des GNNs est basé sur les factorisations et multiplications matricielles, qui sont des opérations intrinsèquement transductives, ces opérations impliquent que toute la structure du graphe soit fournie lors de l'entraînement pour la formation des embeddings. Si un nouveau nœud est ajouté au graphe ultérieurement, le modèle devra être réentraîné.


Apprentissage inductif

Ce type d'apprentissage désigne la capacité d'un modèle à extraire des représentations significatives et généralistes sur les graphes (nœuds, liens, graphes), tout en étant capable de généraliser à de nouveaux (nœuds, liens, graphes) non observés lors de l'entraînement.

- Un graphSage est une variante de GNN, il est basé sur l'apprentissage inductive.
- Il est adapté aux gros graphes qui contiennent beaucoup d'informations au niveau des nœuds.

Entrées / Sorties

- La couche GraphSAGE prend en entrée la matrice X des caractéristiques des n nœuds du graphes et la matrice A , matrice d'adjacence.
- Elle produit en sortie le vecteur d'embeddings associé à chaque nœud.



Fonctionnement

Le fonctionnement d'un GraphSAGE est divisé en deux processus:

- Échantillonnage du voisinage
- Agrégation

Échantillonnage du voisinage

C'est une adaptation aux graphes de la technique mini-batching très utilisé en machine learning.

L'échantillonnage des voisins ne prend en compte qu'un nombre fixe de voisins aléatoires. Voici comment procéder :

- On définit le nombre de voisins (1 saut), le nombre de voisins de voisins (2 sauts), etc. qu'on souhaite avoir.
- La fonction d'échantillonnage examine la liste des voisins, des voisins des voisins, etc. d'un nœud cible et sélectionne au hasard un nombre prédéfini d'entre eux ;
- La fonction d'échantillonnage produit un sous-graphe contenant le nœud cible et les nœuds voisins sélectionnés au hasard.

Ce processus est répété pour chaque nœud d'une liste ou pour l'ensemble du graphe.

Agrégation

C'est le processus qui montre comment les caractéristiques des nœuds voisins d'un nœud donné sont combinées.

On a trois façons d'agréger ces caractéristiques:

- Mean
- LSTM
- Pooling

(1) Agrégation par la moyenne

L'agrégation par la moyenne est le plus simple. L'idée est proche de l'approche GCN :

- Les embeddings du nœud cible et de ses voisins sélectionnés sont moyennés;
- Une transformation linéaire avec une matrice de poids $\mathbf{W}$ est appliquée.

$$\mathbf{h}'_i = \mathbf{W} \cdot \text{mean}_{j \in \tilde{\mathcal{N}}_i} (\mathbf{h}_j)$$

Le résultat peut ensuite être introduit dans une fonction d'activation non linéaire telle que ReLU.

(2) Agrégation par un LSTM Il s'agit de la technique la plus performante dans les benchmarks du papier initial de GraphSAGE. Elle assigne un ordre à nœuds non ordonnés. C'est pourquoi les auteurs les mélangent aléatoirement pour forcer la LSTM à ne prendre en compte que les embeddings considérés.

(3) Agrégation par la pooling

L'agrégation par la pooling transmet le d'embeddings de chaque voisin à un réseau neuronal de type feedforward. Une opération de **max pooling** est appliquée au résultat.

Advantages

- Évolutivité vers de grands graphes.
- Stratégies d'échantillonnage flexibles.
- Convient aux graphes dont les degrés des nœuds varient.

Limits

- Capacité limitée à capturer les structures globales des graphes
- Peut nécessiter plus d'époques pour une formation efficace