

Fonctionnement des GCNs

Sherelle Kana

March 25, 2024

Sommaire

- 1 Introduction
- 2 Entrées / Sorties
- 3 Fonctionnement
- 4 Comparaison CNN vs GCN
- 5 Avantages
- 6 Limites


Introduction

GCN Graph Convolution Neural Networks, est un type de GNN qui utilise sur les graphes le même principe de la **convolution** que dans les CNNs.


Le principe de la couche GCN est le même que celle des GNNs ce qui diffère c'est le fonctionnement de l'aggrégation.

Entrées / Sorties

- La couche GCN prend en entrée la matrice X des caractéristiques des n nœuds du graphes et la matrice A , matrice d'adjacence.
- Elle produit en sortie le vecteur d'embeddings associé à chaque nœud.



Fonctionnement



Le message passing dans la couche de convolution GCN prend en compte en plus des matrices X et A , le vecteur des poids et la fonction d'activation, les matrices:

- I matrice identité de taille $n \times n$
- D la matrice des degrés de $A + I$, il s'agit d'une matrice diagonale où l'élément (i, i) stocke le nombre total de nœuds voisins du nœud i (y compris lui-même).


La couche GCN est la fonction suivante:

$$f(\mathbf{X}, \mathbf{A}) := \sigma \left(\mathbf{D}^{-1/2} (\mathbf{A} + \mathbf{I}) \mathbf{D}^{-1/2} \mathbf{X} \mathbf{W} \right)$$

De cette fonction nous pouvons voir que l'apprentissage dans la couche de convolution se fait en 04 étapes:

- (1) Ajouter des boucles internes : $\mathbf{A} + \mathbf{I}$
- (2) Normalisation de la matrice d'adjacence: $\mathbf{D}^{-1/2} (\mathbf{A} + \mathbf{I}) \mathbf{D}^{-1/2}$
- (3) Aggregation
- (3) Mise à jour

$$f(\mathbf{X}, \mathbf{A}) := \sigma \left(\mathbf{D}^{-1/2} (\mathbf{A} + \mathbf{I}) \mathbf{D}^{-1/2} \mathbf{X} \mathbf{W} \right)$$



Examinons chaque compartiment de la formule ci-dessus:

A+I : cette addition ajoute 1 à chaque valeur diagonale de la matrice d'adjacence. La raison pour laquelle cela est fait c'est parce que durant le **message passing**, chaque nœud considère doit inclure ses propres car-

$$D := \begin{bmatrix} d_{1,1} & 0 & 0 & \dots & 0 \\ 0 & d_{2,2} & 0 & \dots & 0 \\ 0 & 0 & d_{3,3} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & d_{n,n} \end{bmatrix}$$

actéristiques. où $d_{i,i}$ est le nombre de nœuds adjacents au nœud i .

$D^{-1/2}$ Est la matrice formée en prenant la racine carrée inversée de

$$D^{-1/2} := \begin{bmatrix} \frac{1}{\sqrt{d_{1,1}}} & 0 & 0 & \dots & 0 \\ 0 & \frac{1}{\sqrt{d_{2,2}}} & 0 & \dots & 0 \\ 0 & 0 & \frac{1}{\sqrt{d_{3,3}}} & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & \frac{1}{\sqrt{d_{n,n}}} \end{bmatrix}$$

chaque élément dans D.

Multiplier $A+I$ par $D^{-1/2}$ à gauche et à droite, peut être considérée comme une **normalisation** de la matrice d'adjacence A.

Comme A , la matrice $D^{-1/2}(A+I)D^{-1/2}$ n'aura également qu'une entrée non nulle à l'élément i,j seulement si les nœuds i et j sont adjacents.

Notons la matrice normalisée $\tilde{A} = D^{-1/2}(A+I)D^{-1/2}$, ainsi

$\tilde{A}_{ij} = 1/\sqrt{d_{ii}, d_{jj}}$ si $(i,j) \in E$, 0 sinon.

Normalisation

A pour objectif de s'assurer que les nœuds voisins d'un nœud dans une couche GCN aient des poids égaux.


La couche de convolution se résume donc à la fonction suivante: $f(X,A) = \sigma(\tilde{A}XW)$

Le produit matriciel $\tilde{A}X$, assure la fonction d'agrégation et de transmission des messages. En d'autres termes, pour chaque caractéristique, nous faisons la somme pondérée des caractéristiques des nœuds adjacents, les poids étant déterminés par $\tilde{A}$. Soit $\bar{x}_i$ désigne le vecteur au nœud i représentant les caractéristiques agrégées.


$$\begin{aligned}\bar{x}_i &= \sum_{j=1}^n \tilde{a}_{i,j} x_j \\ &= \sum_{j \in \text{Neigh}(i)} \tilde{a}_{i,j} x_j \\ &= \sum_{j \in \text{Neigh}(i)} \frac{1}{\sqrt{d_{i,i} d_{j,j}}} x_j\end{aligned}$$

En d'autres termes, elle est simplement calculée en faisant la somme pondérée des vecteurs voisins, les poids étant stockés dans la matrice d'adjacence normalisée.

Lors de la multiplication matricielle suivante, nous "mettons à jour" les vecteurs de caractéristiques agrégés en fonction de ces poids via $\tilde{A}XW$. Ces vecteurs sont ensuite transmis à la fonction d'activation, σ avant d'être restitués par la couche. Cette fonction d'activation injecte de la non-linéarité dans le modèle.



Visualisation de la couche GCN empilée




$$H1=fW1(X,A)$$


$$H2=fW2(H1,A)$$

$$H3=fW3(H2,A)$$

$H1$, $H2$ et $H3$ sont les vecteurs de nœuds intégrés aux couches 1, 2 et 3 respectivement. Les matrices $W1$, $W2$ et $W3$ sont les matrices de poids qui paramètrent chaque couche.

Comparaison CNN vs GCN





Advantages

- Interprétabilité: grâce à l'analyse des embeddings de nœuds et des messages propagés entre les nœuds.

Limits

- Deux nœuds ayant la même matrice d'adjacence auront la même matrice d'embedding en sortie. Par conséquent, les couches peuvent faire oublier au réseau les informations spécifiques aux nœuds si nous prenons simplement une moyenne sur tous les messages.